3º WORKSHOP DO BI0S · SESSÃO DE PÔSTER

Pôster nº 04

Quantização em LLMs locais: caracterização do custo energético e de carbono da inferência

Guilherme de Medeiros Ellena[1]

[1] Matemática Aplicada e Computacional, Instituto de Matemática, Estatística e Computação Científica (IMECC), Unicamp, Campinas–SP · Contato: g256774@dac.unicamp.br

UNICAMP

01 Introdução

Quantizar um LLM é guardar seus pesos em 8 ou 4 bits em vez de 16. A memória cai pela metade ou mais, mas isso não garante gastar menos energia. E a mesma energia emite CO_2 muito diferente conforme a rede elétrica.

02 Objetivos

Caracterizar o custo energético e de carbono da inferência de LLMs locais quantizados:

1. A quantização sempre reduz a energia?

2. Por que às vezes ela gasta mais?

3. Quanto CO_2 isso emite, e o que pesa mais: formato, lote ou rede?

4. Ela custa qualidade? O MMLU avisa?

03 Metodologia

Parte A: 5 modelos, de 1,7B a 8B, em original × NF4, com perguntas de 14 domínios.

Parte B: os dois de 8B (Qwen3-8B e Llama-3.1-8B) em 7 configurações: 6 formatos, com o INT8 em duas implementações (Figura 1).

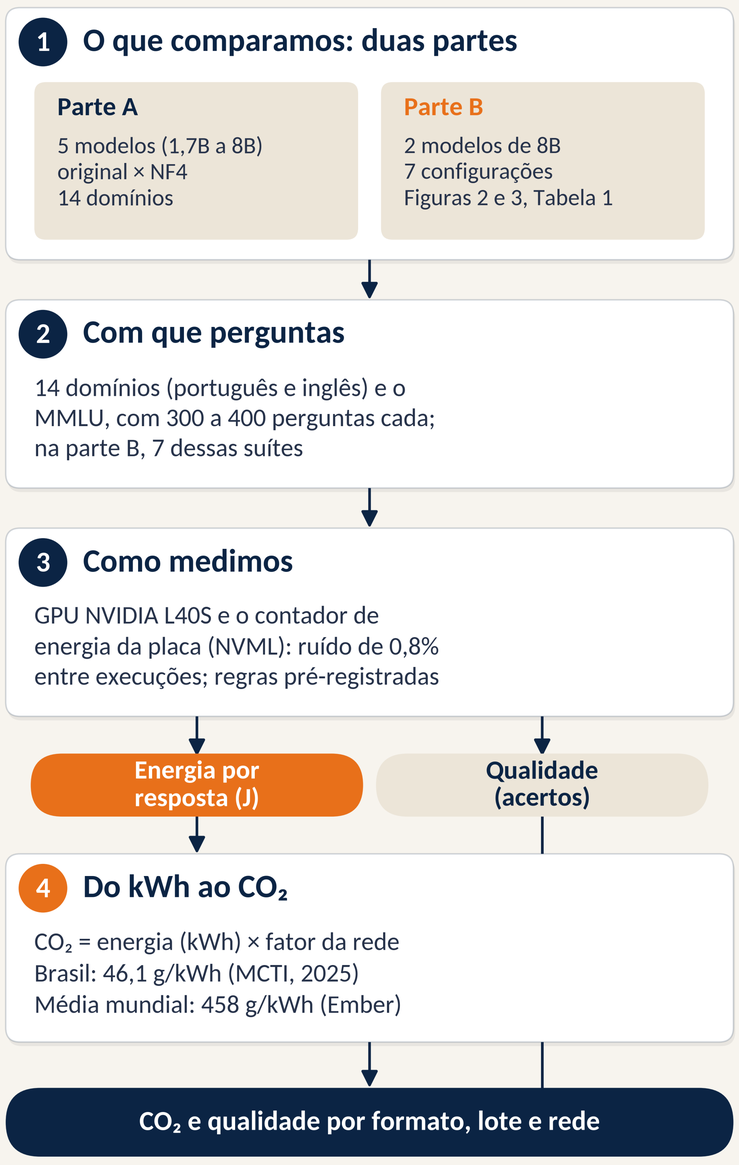


Figura 1. Como medimos: da configuração ao CO_2 por resposta. Fonte: autoria própria.

04 Resultados

Comprimir reduz a energia em até 74%, mas nem todo formato economiza. Onde se roda e quantas perguntas se atende de uma vez pesam mais que o formato.

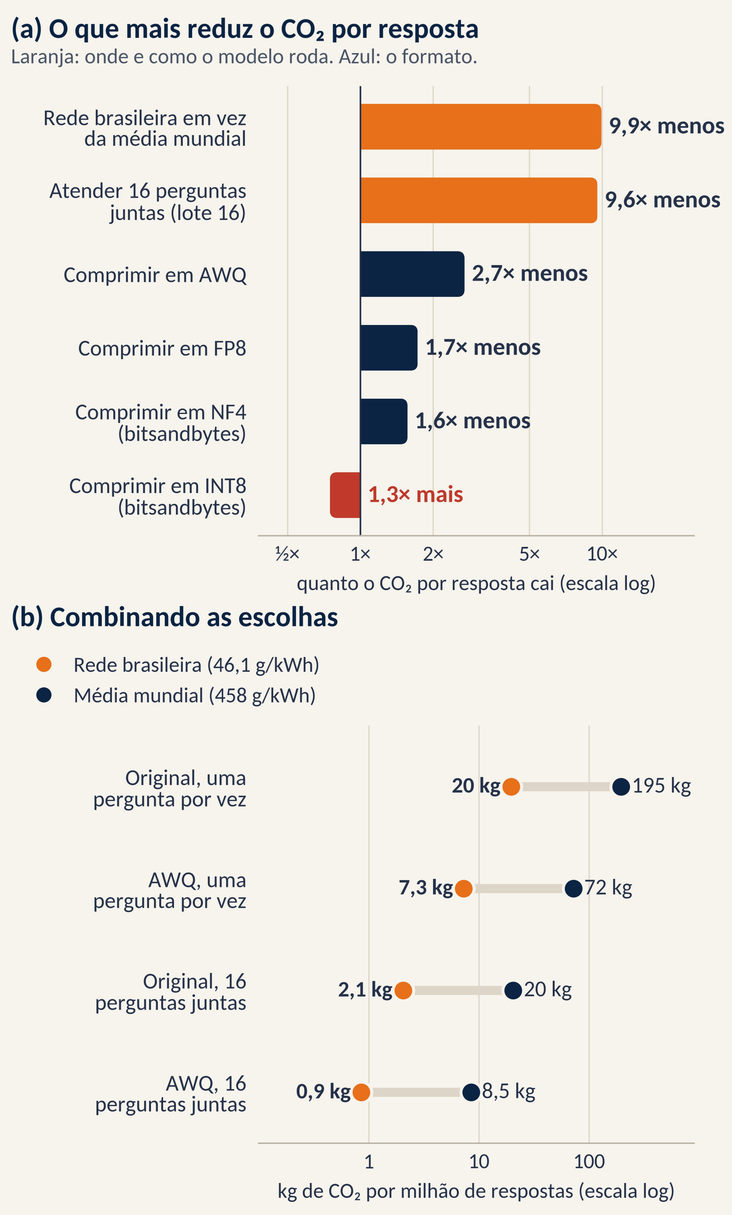


Figura 2. Parte B, Qwen3-8B. (a) Quanto cada escolha reduz o CO_2 por resposta; (b) kg de CO_2 por milhão de respostas, com 256 tokens de pergunta e de resposta. Fonte: autoria própria; fatores: MCTI (2026) e Ember (2026).

Formato	Energia vs. original	kg CO_2 / milhão, Brasil	kg CO_2 / milhão, mundo	Pior perda (p.p.)
BF16 (original)	—	19,3	192	—
FP8	−42%	11,3	112	−3,3
INT8 (vLLM)*	−44%	10,5	105	−1,3
GPTQ	−64%	6,9	68	**−7,0**
AWQ	−64%	7,0	69	**−10,3**
NF4 (bnb)	−41%	12,1	121	**−14,7**
INT8 (bnb)	**+25%**	25,8	256	−3,7

Tabela 1. Parte B: as 7 configurações, média de Qwen3-8B e Llama-3.1-8B, uma pergunta por vez; pior perda entre 7 suítes. O INT8 aparece em duas implementações: W8A8 no vLLM e LLM.int8 no bitsandbytes (bnb). Fonte: autoria própria. * Só Llama-3.1-8B: o checkpoint do Qwen3-8B é incompatível.

05 Discussão

Rede e lote pesam mais que o formato: no Brasil, a mesma resposta emite ~10× menos CO_2 que na média mundial; 16 perguntas juntas gastam de 5 a 10× menos.

Comprimir pode sair caro: o INT8 do bitsandbytes gasta mais que o original.

O MMLU não avisa: no Qwen3-8B em NF4, ele não perde nada; finanças perde 14,7 p.p. (Figura 3).

Limitações: uma GPU; só a energia da GPU; sem o carbono da fabricação.

06 Conclusões

Quantizar reduz a energia em até 74%, mas nem todo formato economiza. Rodar numa rede limpa e agrupar perguntas pesam tanto quanto comprimir. Antes de comprimir, teste no seu domínio.

Referências

BRASIL. Ministério da Ciência, Tecnologia e Inovação. Fatores de emissão de CO_2 da geração de energia elétrica no Sistema Interligado Nacional. Brasília: MCTI/SIRENE, 2026. Acesso em: 12 out. 2026.

EMBER. Global Electricity Review 2026. Londres: Ember, 2026.

DETTMERS, T. et al. QLoRA: efficient finetuning of quantized LLMs. arXiv:2305.14314, 2023.

FRANTAR, E. et al. GPTQ: accurate post-training quantization for generative pre-trained transformers. arXiv:2210.17323, 2022.

LIN, J. et al. AWQ: activation-aware weight quantization for LLM compression and acceleration. arXiv:2306.00978, 2023.

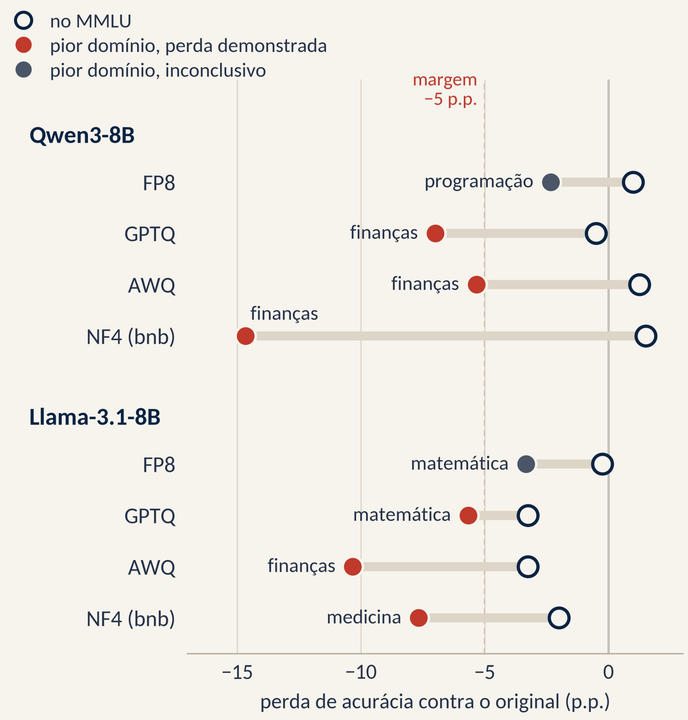


Figura 3. Parte B: perda de acurácia no MMLU e no pior domínio, nos dois modelos de 8B. Fonte: autoria própria.

Agradecimentos

Ao Recod.ai (IC/Unicamp), pelo acesso ao cluster de GPUs.