3º WORKSHOP DO BI0S · SESSÃO DE PÔSTER

Pôster nº 04

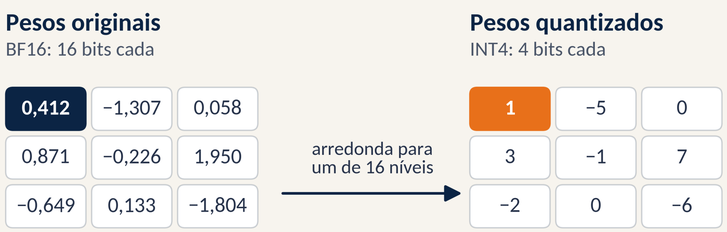
Quantização em LLMs locais: caracterização do custo energético e de carbono da inferência

Guilherme de Medeiros Ellena[1]

[1] Matemática Aplicada e Computacional, Instituto de Matemática, Estatística e Computação Científica (IMECC), Unicamp, Campinas–SP · Contato: g256774@dac.unicamp.br

01 Introdução

Quantizar um LLM é armazenar seus pesos com menos bits (Figura 1). A memória ocupada cai pela metade ou mais, mas isso não garante menor consumo de energia. Além disso, a mesma energia emite quantidades muito diferentes de CO_2 conforme a rede elétrica.



Exemplo: 0,412 ÷ escala (0,279) = 1,48 → guarda o código 1. Para usar, a GPU reconstrói 1 × 0,279 = 0,279: perde precisão e gasta um passo extra a cada uso. Em troca, a memória cai 4 vezes.

Figura 1. O que é quantizar: cada peso vira um de 16 níveis, guardado em 4 bits (exemplo com quantização uniforme). Fonte: autoria própria.

02 Objetivos

Caracterizar a energia e o carbono da inferência quantizada, respondendo a:

1. A quantização sempre reduz a energia?

2. Por que, em alguns casos, ela aumenta o consumo?

3. Quanto CO_2 se emite, e o que pesa mais: formato, lote ou rede?

4. Ela reduz a qualidade? Um benchmark genérico detecta isso?

03 Metodologia

Parte A: 5 modelos, de 1,7B a 8B, em original × NF4, com perguntas de 14 domínios.

Parte B: os dois de 8B (Qwen3-8B e Llama-3.1-8B) em 7 configurações: 6 formatos, com o INT8 em duas implementações (Figura 2).

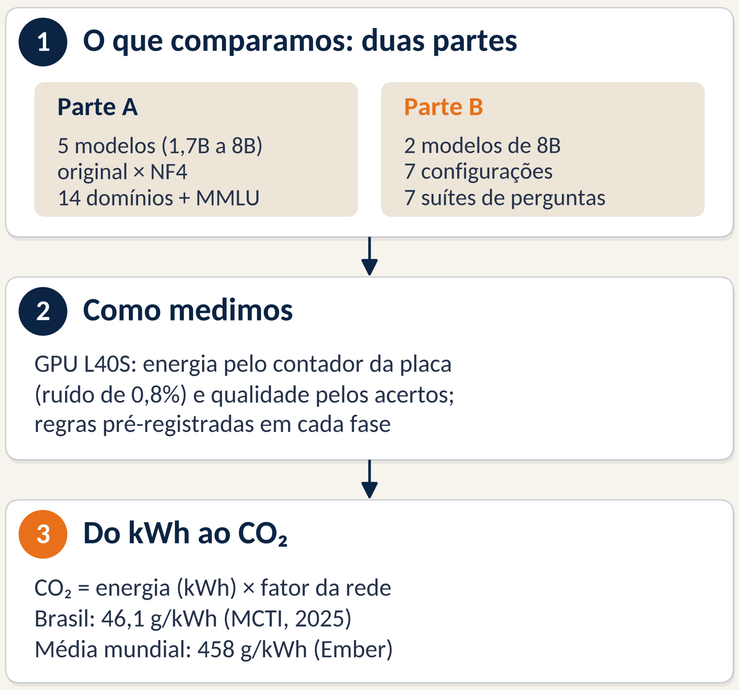


Figura 2. Como medimos. Fonte: autoria própria.

04 Resultados

A compressão reduziu a energia em até 74%, mas um dos formatos consumiu mais que o original. A rede elétrica e o número de perguntas atendidas por vez pesaram mais que o formato (Figura 3).

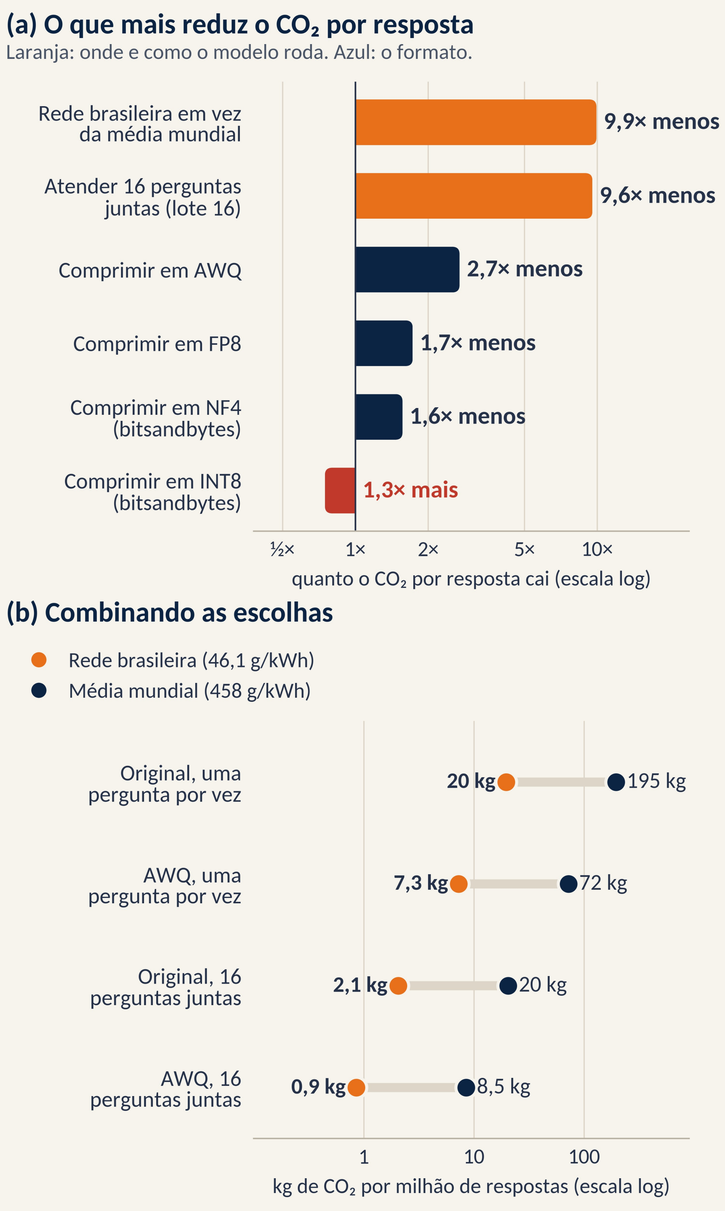


Figura 3. Parte B, Qwen3-8B. (a) Quanto cada escolha reduz o CO_2 por resposta; (b) kg de CO_2 por milhão de respostas, com 256 tokens de pergunta e de resposta. Fonte: autoria própria; fatores: MCTI (2026) e Ember (2026).

Formato	Energia vs. original	kg CO_2 / milhão, Brasil	kg CO_2 / milhão, mundo	Pior perda (p.p.)
BF16 (original)	—	19,3	192	—
FP8	−42%	11,3	112	−3,3
INT8 (vLLM)*	−44%	10,5	105	−1,3
GPTQ	−64%	6,9	68	**−7,0**
AWQ	−64%	7,0	69	**−10,3**
NF4 (bnb)	−41%	12,1	121	**−14,7**
INT8 (bnb)	**+25%**	25,8	256	−3,7

Tabela 1. Parte B: as 7 configurações, média de Qwen3-8B e Llama-3.1-8B, uma pergunta por vez; pior perda entre 7 suítes. O INT8 aparece em duas implementações: W8A8 no vLLM e LLM.int8 no bitsandbytes (bnb). Fonte: autoria própria. * Só Llama-3.1-8B: o checkpoint do Qwen3-8B é incompatível.

05 Discussão

Onde e como o modelo roda pesam mais que o formato: na rede brasileira, a mesma resposta emite cerca de 10 vezes menos CO_2 que na média mundial, e atender 16 perguntas por vez reduz a energia de 5 a 10 vezes.

Nem toda compressão economiza: o INT8 do bitsandbytes consumiu 25% mais que o original.

Um bom resultado no MMLU não garante o do domínio: no Qwen3-8B em NF4, a acurácia no MMLU não caiu, mas em finanças caiu 14,7 pontos (Figura 4).

Limitações: uma única GPU, só a energia da GPU e sem o carbono da fabricação.

06 Conclusões

A quantização reduziu a energia em até 74%, mas nem todo formato economiza. A rede elétrica e o lote pesam tanto quanto o formato, e a perda de qualidade depende do domínio.

Referências

Referências completas na página do QR code:
medeirosdev.github.io/WorkshopBIOSQRCodePoster

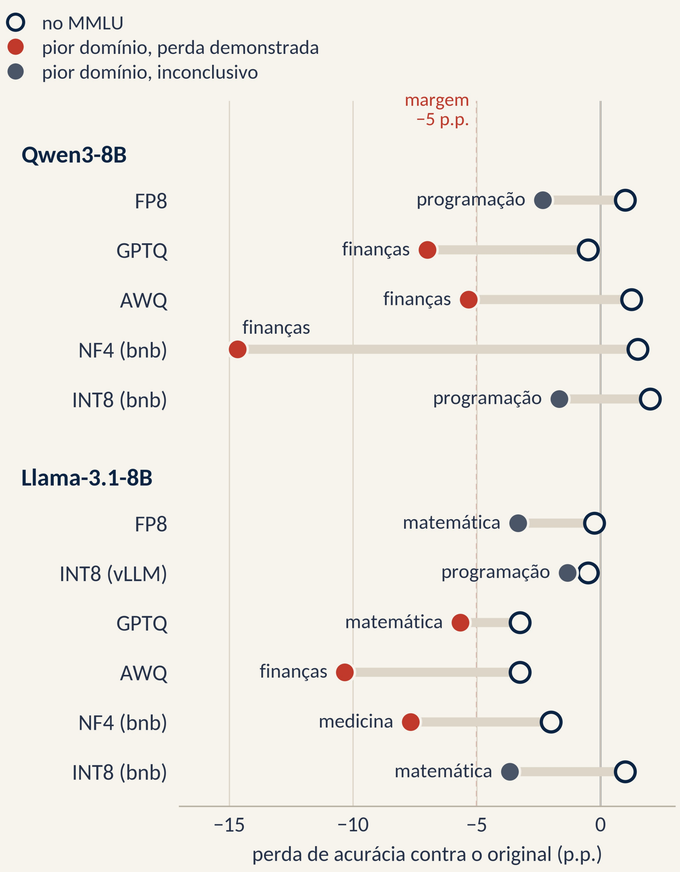


Figura 4. Parte B: perda de acurácia no MMLU e no pior domínio. O MMLU é um benchmark genérico de múltipla escolha, com questões de 57 áreas, muito usado para comparar modelos. Fonte: autoria própria.

Agradecimentos

Ao Recod.ai (IC/Unicamp), pelo acesso ao cluster de GPUs.